



移动扫码阅读

DOI:10.13347/j.cnki.mkaq.2022.10.028

成小雨,周爱桃,郭焱振.基于随机森林与支持向量机的回采工作面瓦斯涌出量预测方法[J].煤矿安全,2022,53(10):205-211.

CHENG Xiaoyu, ZHOU Aitao, GUO Yanzhen, et al. Prediction method of gas emission based on random forest and support vector machine[J]. Safety in Coal Mines, 2022, 53(10): 205-211.

基于随机森林与支持向量机的回采工作面 瓦斯涌出量预测方法

成小雨¹,周爱桃²,郭焱振²,程 成¹,李德波³

(1.中煤能源研究院有限责任公司,陕西 西安 710054;2.中国矿业大学(北京) 应急管理与安全
工程学院,北京 100083;3.中煤新集刘庄矿业有限公司,安徽 阜阳 236200)

摘 要:针对当前回采工作面瓦斯涌出量预测方法选取不合理及预测精度不佳问题,借助机器学习方法对其展开研究,以交叉验证法处理现有数据,构建了支持向量回归模型与随机森林回归预测模型,并对输入数据降维前后2种模型的预测表现进行了对比分析。测试表明:经交叉验证及数据降维后2种预测模型趋于稳定、预测精度均有大幅提高,SVR模型的整体预测性能稍优于RFR模型,SVR模型每轮测试耗时约0.015 s,远低于后者;筛选后的SVR模型平均绝对误差约为0.18 m³/min,平均相对误差约3.26%,优于RFR预测模型;建立的回采工作面瓦斯涌出量预测模型均表现良好,经随机森林筛选的SVR预测模型耗时较短、误差较小、稳定性更好,可实现对瓦斯涌出量的有效预测,对简化数据采集工作及科学制定瓦斯防治措施起到参考作用。

关键词:瓦斯涌出量预测;交叉验证;随机森林;支持向量机;特征选择

中图分类号:TD713+.2

文献标志码:A

文章编号:1003-496X(2022)10-0205-07

Prediction method of gas emission based on random forest and support vector machine

CHENG Xiaoyu¹, ZHOU Aitao², GUO Yanzhen², CHENG Cheng¹, LI Debo³

(1.China Coal Energy Research Institute Co., Ltd., Xi'an 710054, China; 2. School of Emergency Management and
Safety Engineering, China University of Mining and Technology(Beijing), Beijing 100083, China;

3.China Coal Xinji Liuzhuang Mining Co., Ltd., Fuyang 236200, China)

Abstract: In order to solve the problems of unreasonable selection of prediction methods and poor prediction accuracy for gas emission in mining face, with the help of machine learning methods, in this paper, existing data was processed through cross-validation, the support vector and the random forest algorithm were used to construct the prediction model and the prediction performance of the two models before and after dimensionality reduction of the input data were compared and analyzed. The test shows that after cross-validation and data dimensionality reduction, the two prediction models tend to be stable, and the prediction accuracy are greatly improved. The overall prediction performance of the SVR model is slightly better than that of the RFR model; SVR model takes about 0.015 s per round of testing, much lower than the latter one; the average absolute error of the SVR model is about 0.18 m³/min, and the average relative error is about 3.26%, which is relatively better than the other one. The models established in this paper both present good performance, and the SVR model after feature screening by random forest takes less time, has less error and better stability, which effectively realizes the prediction of the gas emission and plays a reference role in simplifying data collection and scientifically formulating gas control measures.

Key words: gas emission prediction; cross validation; random forest; support vector machine (SVM); feature selection

瓦斯涌出量是指在矿井建设及生产过程中从煤
与岩石内涌出的瓦斯量,是煤矿安全生产的主要威

胁之一^[1]。通过对矿井瓦斯涌出量进行预测,进而采
取必要的防范措施可以减少乃至有效预防瓦斯事故

的发生,从而保证矿井安全生产以及保障工作人员生命安全。开采过程中,瓦斯涌出量随自然条件和开采技术变化而改变,这些因素间存在着耦合性、非线性^[2]。近年来许多学者从深度学习领域积极探寻瓦斯涌出量的预测方法:王艳晖等^[3]基于改进果蝇算法(MFOA)结合支持向量机(SVM)对瓦斯涌出量进行了预测;董晓雷等^[4]将遗传算法(GA)与支持向量机(SVM)结合,建立了回采工作面瓦斯涌出量预测模型;王生全等^[5]借助 BP 神经网络结合遗传算法(GA)建立了瓦斯涌出量预测模型。部分学者将特征筛选方法^[6]运用到瓦斯涌出量预测中:李树刚等^[7]将因子分析与 BP 神经网络结合,对瓦斯涌出量预测展开了研究;卢国斌等^[8]借助主成分分析法结合 BP 神经网络对回采工作面瓦斯涌出量进行预测;付华等^[9]提出一种基于 LSTM 的瓦斯涌出量预测模型,并结合量子粒子群算法对相关参数进行了优化,测试表明该模型有着较好的表现;吴奉亮等^[10]、汪明等^[11]提出了以随机森林算法进行瓦斯涌出量预测的方法。从前人研究来看,灰色理论在预测精度上难以满足要求;神经网络类深度学习方法调参耗时费力,对数据要求较高且易过拟合。支持向量机与随机森林算法以其原理清晰等优点在农业^[12]、生物学^[13]、地球物理^[14-15]等领域得到广泛应用。此外,部分学者将随机森林自身特征筛选功能与支持向量机(SVM)结合展开了相关研究^[16-17],结果表明,与未进行特征筛选相比,该方法在有效减少数据采集工作量的同时,基本取得了较为接近甚至更为理想的效果,这为解决该类多影响因素问题提供了思路:可以采取数据降维类方法对影响因素进行筛选后结合相关算法进行求解。为此,针对当前瓦斯涌出量预测中数据处理粗糙及数据利用程度不足等问题,将交叉验证、数据降维方法结合对数据进行处理;针对预测方法单一、预测方法选取不合理问题,选取支持向量机与随机森林算法分别建立预测模型,通过对比筛选出较优的瓦斯涌出量预测模型。

1 方法原理

1.1 随机森林原理

随机森林^[18]是由多个决策树构成的集成算法,属于集成学习的一个子类,可用于分类及回归问题,它主要对样本单元和变量进行抽样,进而生成大量决策树。对每个样本单元来说,所有决策树依次对其进行分类,预测类别中的众数即为随机森林所预测的该样本单元所属类别(用于回归时,输出

即为所有树预测值的均值)。

假设给定样本集 X 中共有 N 个样本单元, M 个特征属性,用于回归问题时随机森林算法大致如下:①采用 Bootstrap 法从给定样本集 X 中随机、有放回地抽取 Q 个样本,生成决策树;②在每一个节点随机抽取 m 个特征($m < M$),将其作为分割该节点的候选特征,每一节点处的特征数应一致;③完整生成所有决策树,无需剪枝(最小节点为 1);④对于新的样本点,用所有树对其预测,取各个树预测值的均值为模型最终预测值。

进行预测时,通过引入随机抽取子样本与随机选取特征因素进行节点分裂 2 个随机过程,降低各回归树间的相关性,进而减小随机森林回归模型的泛化误差。重抽样时,每个样本未被抽到的概率为 $(1 - \frac{1}{N})^N$,当 N 足够大时这一概率趋于 0.368,即是说将有约 37% 的样本不会被抽到,这些样本将组成袋外数据(OOB),可以通过观测袋外数据的误差来调整模型。随机森林算法原理如图 1。

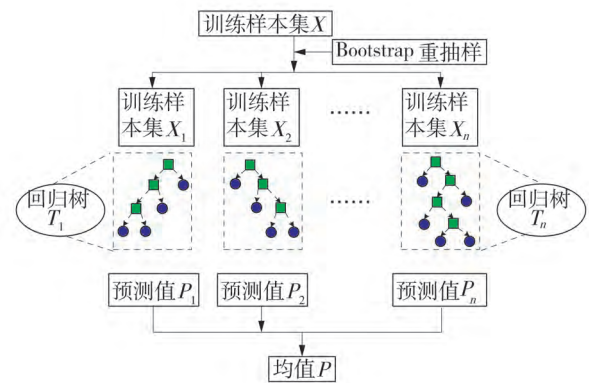


图 1 RF 原理图

Fig.1 Principle diagram of random forest

1.2 支持向量机原理

支持向量机是一种监督式机器学习模型,可用于分类及回归分析。处理非线性问题时借助核技巧将其由原始空间映射到高维空间,转换为该空间内的线性问题,进而寻找一超平面使得所有样本与该超平面的距离最小。该超平面的表达式可写作:

$$f(x) = \omega^T \varphi(x_i) + b \quad (1)$$

式中: ω 为权值向量; b 为偏置值; $\varphi(x_i)$ 为非线性映射函数。

将上述问题转化为二次规划问题:

$$\min \frac{1}{2} \|\omega\|^2 + C \sum_{i=1}^m (\xi_i + \xi_i^*) \quad (2)$$

式中： ξ_i, ξ_i^* 为松弛变量； C 为惩罚系数。

借助 Lagrange 优化方法将上述问题转化为对偶问题，最终得到回归模型表达式为：

$$f(x) = \sum_{i=1}^m (\alpha_i - \alpha_i^*) K(x_i, x_j) + b \quad (3)$$

式中： α_i, α_i^* 为拉格朗日乘子； $K(x_i, x_j)$ 为核函数。

约束条件：

$$s.t. \begin{cases} \sum_{i=1}^m (\alpha_i - \alpha_i^*) = 0 \\ 0 \leq \alpha_i \leq C, 0 \leq \alpha_i^* \leq C \end{cases} \quad (4)$$

径向基核函数(RBF)表达式为：

$$K(x_i, x_j) = (\varphi(x_i) \varphi(x_j)) = \exp\left(-\frac{1}{2\sigma} \|x_i - x_j\|^2\right)$$

式中： σ 为RBF 的径向量宽度。

2 实验及分析

2.1 数据来源和数据处理

实验所用样本数据取自中煤新集刘庄煤矿若干工作面历史监测数据，整理共计 24 组，回采工作面瓦斯涌出量与影响因素见表 1^[19-20]。

表 1 回采工作面瓦斯涌出量与影响因素

Table 1 Gas emission and influencing factors in mining face

序号	$I_1/$ ($\text{m}^3 \cdot \text{t}^{-1}$)	I_2/m	I_3/m	$I_4/(\circ)$	I_5/m	I_6/m	I_7/m	I_8	$I_9/$ ($\text{m}^3 \cdot \text{t}^{-1}$)	I_{10}/m	I_{11}/m	I_{12}	I_{13}	I_{14}	$O/$ ($\text{m}^3 \cdot \text{min}^{-1}$)
1	3.90	499	4.3	15	4.3	10	280	0.93	3.10	2.80	52.0	1	8	5.89	2.71
2	3.16	502	2.7	8	2.7	10	290	0.93	2.80	1.79	48.0	1	10	4.90	2.84
3	3.40	522	3.4	12	3.4	8	280	0.95	2.15	1.72	14.0	1	8	4.71	3.20
4	2.96	540	2.8	10	2.8	8	290	0.95	2.44	2.20	20.0	1	10	4.24	3.60
5	3.68	513	3.5	12	3.5	9	285	0.94	3.28	1.80	19.0	1	6	4.54	3.10
6	3.35	542	5.3	11	4.7	10	300	0.95	4.20	4.20	46.0	1	8	4.20	3.88
7	2.88	568	2.8	15	2.8	8	280	0.95	2.34	2.34	18.6	1	9	4.68	4.00
8	2.58	524	2.9	9	2.9	10	270	0.95	4.00	3.60	18.0	1	9	4.41	3.45
9	3.73	570	3.7	11	3.7	10	270	0.92	3.19	4.31	16.0	1	8	3.36	4.16
10	3.87	590	3.9	16	3.9	10	290	0.92	3.00	1.39	14.2	1	8	3.34	4.29
11	3.86	585	4.0	13	4.0	10	280	0.95	3.31	1.04	14.4	1	9	4.08	4.43
12	2.90	605	3.2	11	3.2	9	285	0.95	3.92	3.69	20.0	1	9	3.30	4.66
13	3.90	606	5.6	9	5.0	10	295	0.95	3.30	3.62	16.0	1	8	4.78	4.82
14	3.93	618	2.9	13	2.9	10	315	0.95	2.46	3.60	15.8	1	11	3.98	5.02
15	3.45	652	3.7	12	3.7	10	290	0.95	2.23	1.20	15.0	1	10	4.00	6.10
16	4.67	682	5.8	11	5.8	10	280	0.94	2.53	3.20	16.0	1	10	3.31	6.32
17	5.20	711	4.9	14	4.9	10	300	0.93	3.29	3.10	18.0	1	11	3.92	7.34
18	4.91	701	3.8	10	3.8	10	280	0.95	4.62	3.15	55.0	1	7	5.00	7.02
19	3.56	684	3.5	11	3.4	10	285	0.93	2.89	1.13	17.6	1	9	3.20	6.88
20	4.81	713	3.3	10	3.3	10	290	0.95	2.56	1.38	20.0	1	10	3.36	7.10
21	4.17	620	3.1	14	3.0	10	315	0.95	2.09	1.34	20.0	1	11	3.33	5.21
22	4.50	635	5.2	10	5.2	10	280	0.94	2.94	3.86	17.0	1	10	3.86	5.43
23	3.62	638	4.2	9	4.2	8	260	0.95	3.23	2.91	64.0	1	9	5.12	5.60
24	4.82	650	5.2	12	5.2	10	300	0.95	3.42	3.88	15.0	1	10	3.85	5.82

注： I_1 为煤层瓦斯含量； I_2 为煤厚； I_3 为埋深； I_4 为倾角； I_5 为采煤高度； I_6 为每日进度； I_7 为工作面长度； I_8 为采出率； I_9 为邻近层瓦斯含量； I_{10} 为邻近层厚度； I_{11} 为邻近层间距； I_{12} 为顶板管理方式； I_{13} 为开采强度等级； I_{14} 为层间岩性等级； O 为瓦斯涌出量；其中， $I_1 \sim I_{14}$ 为预测模型的输入指标； O 为预测模型的输出量。

为充分利用现有数据，综合考虑数据量及测试稳定性，采取 K -折交叉验证 (K -CV) 处理数据集， K -折交叉验证原理如图 2。

具体做法如下：

将数据集均分成 K 份规模相同互斥子集，每次取其中 $K-1$ 份子集进行训练，余下 1 组作为测试集，

如此循环直至所有子集都作一次测试集。一般 K 从 3 取起，当 K 与样本数相等时即为留一法交叉验证。

2.2 预测模型构建

相关预测模型构建工作均借助 Python 编程语言中 Sklearn 机器学习工具进行。支持向量回归模型 (SVR) 中核函数有线性核、多项式核及高斯核

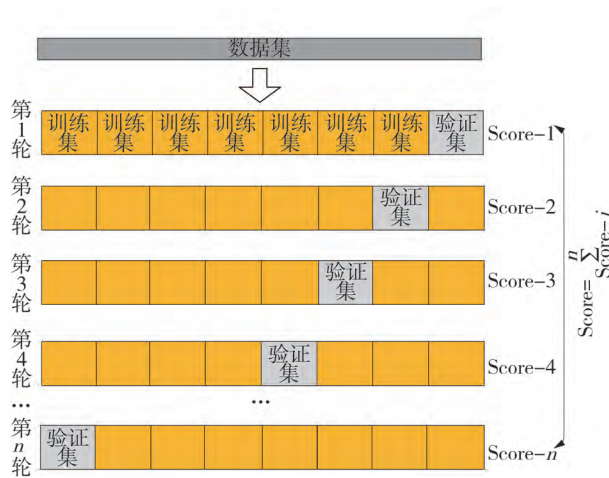


图 2 K-折交叉验证

Fig.2 K-fold cross validation

(RBF)等,这里选取泛化能力强、待调参数少的 RBF 为核函数,惩罚系数 C 与 σ 按网格搜索法确定,其中 C 搜索范围:[1、5、10、15、20、50、100、200]; σ 搜索范围:[0.01、0.02、0.03、0.04、0.05、0.1、0.2、0.5、1、5、10]。

随机森林回归模型(RFR)中待调节参数主要有 2 个:树的数量 N 以及最大特征数 M ,以网格搜索法确定二者取值,设置 N 的范围为 50~500,梯度 50;最大特征数取值方法有开方取值法、取对数值法、取整数法等,为了节省测试时间及直观查看其值对预测效果的影响,按取整数法设置 M 搜索范围为 3~10,梯度为 1,其余参数按默认值选取。

2.3 实验流程

瓦斯涌出量预测模型构建流程如图 3。




图 3 瓦斯涌出量预测模型构建流程

Fig.3 Flow chart of establishing gas emission prediction model

首先以交叉验证法对数据集随机拆分(shuffle=True)处理,通过 SVR、RFR 预测模型得到各个子集预测结果,对其效果进行对比分析。

随后对特征筛选后数据集进行测试,经对比得到最优预测模型,并进一步对模型效果验证及

分析。为确保测试合理性与可对比性,除预测模型中参数设置外,2 模型在其余处理上均保持同步。

2.4 K-折交叉验证(K-CV)

为增加测试可信度, K 值一般从 3 取起,但随着 K 值增加模型性能趋于稳定,而工作量也会随之增加。通过查阅相关文献确定在工程应用中 K 值取作 5 和 10^[21]。综上,为动态表述模型性能随折数 K 变化趋势,设定 K 范围为 3~10,并从 MSE、MAE、测试耗时 T 3 个方面来考察模型性能,不同模型 MSE、MAE、测试耗时 T 与折数关系图如图 4。

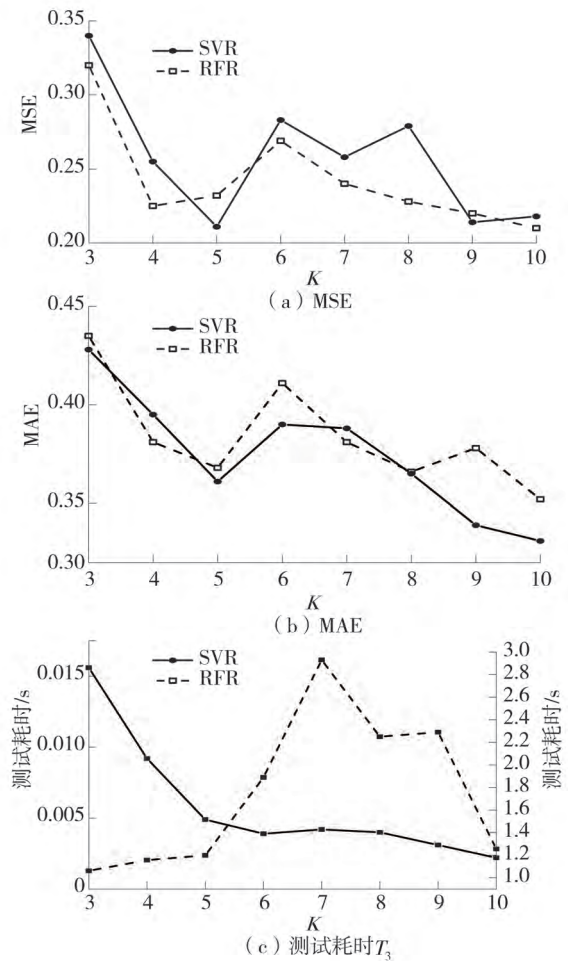


图 4 不同模型 MSE、MAE、测试耗时 T 与折数关系图

Fig.4 Relationship between MSE, MAE, test time T and fold number of different models

1)随折数 K 增加,2 种模型的预测误差均呈现出下降趋势,并在 $K=10$ 时达到相对较低水平,MSE 稳定在 0.21 左右,此时 SVR 模型参数 C 为 20, σ 为 0.01;RFR 模型参数取值 N 为 100, M 为 10。

2)从测试耗时 T 来看,SVR 模型每轮耗时约在 0.015 s 甚至更低,而 RFR 模型耗时约 1~3 s,远高于前者。因此,SVR 模型整体表现上稍优于后者。

2.5 留一法(Leave-one-out)交叉验证

为探究 10-折交叉验证与留一法交叉验证效果优劣,对数据集进行留一法处理后得到相关指标,得到留一法处理下 SVR 模型参数 C 为 50、 σ 为 0.01,RFR 模型参数为 N 为 250、 M 为 10。不同交叉验证方法效果对比见表 2。

表 2 不同交叉验证方法效果对比

Table 2 Comparison of different cross-validation methods

模型	SVR			RFR		
	MSE	MAE	T	MSE	MAE	T
10-CV	0.218	0.331	0.002 2	0.210	0.352	1.255
留一法	0.205	0.330	0.015 5	0.202	0.365	7.827

留一法处理后模型性能有着小幅提升,测试过程中模型误差较为稳定,表现也相对优于 10-折交叉验证,因此最终确定按留一法对数据集进行处理,不同模型预测效果对比图如图 5。




图 5 不同模型预测效果对比图

Fig.5 Comparison of prediction performance of different models

2.6 特征筛选和结果分析及模型验证

应用随机森林算法获得 14 个输入因素中特征重要度前 8 位的因素依次为埋深、层间岩性、煤层瓦斯含量、邻近层厚度、煤厚、开采强度、采高、采出率,其值依次为 0.539、0.151、0.116、0.042、0.04、0.033、0.022、0.021,累计重要程度达到 95%以上。将其余因素“剔除”后建立新的数据集进行测试。

测试需调整 RFR 模型中参数 M 范围为 3~8,梯度为 1,其余设置不做改动。测试得到 SVR 模型参数 C 为 100、 σ 为 0.01;RFR 模型参数 N 为 350、 M 为 8。特征筛选前后效果对比见表 3,特征筛选后 2 种模型预测效果对比图如图 6。

表 3 特征筛选前后效果对比

Table 3 Comparison of indicators before and after feature screening

模型	SVR			RFR		
	MSE	MAE	T	MSE	MAE	T
筛选前	0.205	0.334	0.015 5	0.202	0.365	7.827
筛选后	0.073	0.216	0.015 6	0.104	0.260	10.900

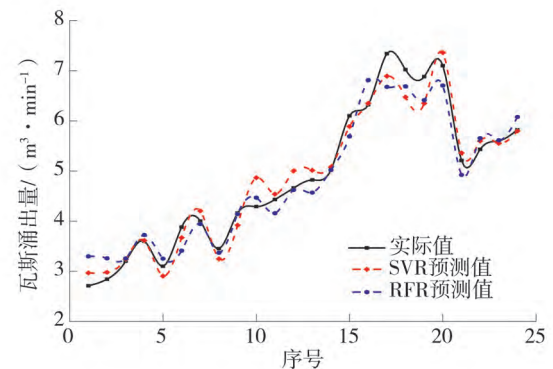


图 6 特征筛选后 2 种模型预测效果对比图

Fig.6 Comparison of prediction performance of different models after feature screening

1)对输入因素进行降维处理后,2 种模型的预测性能均有大幅提高,MSE 值降低近 50%,MAE 减少约 30%;其中 SVR 模型 MSE 值降低至 0.073,MAE 值低至 0.216 左右。

2)测试耗时方面,SVR 模型基本稳定在 0.015 5 s,而后者最高增加至 10 s 左右,可能是建树量增加造成。

3)除极个别样本点波动稍大外,2 模型预测值与瓦斯涌出量真实值误差较小,几乎吻合。特征筛选后的预测模型均展现出了较好的预测效果。

选取处于回采阶段的若干工作面进行测试,验证工作面相关参数见表 4,不同模型预测误差对比见表 5,可以看出 SVR 预测模型的性能最优,其平均绝对误差约为 0.18 m³/min,平均相对误差约 3.26%。

表 4 验证工作面相关参数

Table 4 Relevant parameters of selected mining faces

编号	煤层瓦斯含量/(m³·t⁻¹)	煤厚/m	埋深/m	采高/m	采出率	邻近层厚度/m	开采强度	层间岩性	瓦斯涌出量/(m³·min⁻¹)
150801	3.90	3.5	580	4.0	0.95	4.0	6	4.20	4.75
171105	3.92	4.0	671	4.0	0.95	3.0	8	5.80	6.60
131103	3.80	2.7	660	2.7	0.95	3.8	9	5.66	5.75

表 5 不同模型预测误差对比

Table 5 Comparison of gas emission prediction error of different models

工作面 编号	实测值/ (m ³ ·min ⁻¹)	RFR			SVR		
		预测 值	绝对 误差	相对 误差/%	预测 值	绝对 误差	相对 误差/%
150801	4.75	4.31	0.44	9.26	4.59	0.16	3.37
171105	6.60	6.27	-0.33	5.00	6.46	-0.16	2.42
131103	5.75	5.93	0.18	3.13	5.52	-0.23	4.00
平均值			0.32	5.79		0.18	3.26

3 结 语

选取影响煤矿瓦斯涌出量的 14 个参数为特征,结合中煤新集刘庄煤矿历史监测数据,对数据进行交叉验证及降维处理,运用支持向量机与随机森林算法对工作面瓦斯涌出量预测进行了研究。

1)通过观测 2 种预测模型性能随交叉验证折数 K 变化情况,得到 10 折交叉验证相对较优;与留一法交叉验证进行二次对比后,确定以留一法进行数据处理时模型更为稳定、精度更高。

2)SVR 模型每轮测试耗时约在 0.015 s 甚至更低,而 RFR 预测模型则由 0.3 s 开始增加,最高达 10 s 左右,推测由于建树量增加导致。

3)对输入进行降维后,2 种模型的预测性能有着显著提升,其中 RBF-SVR 模型 MSE 低至 0.073;进一步验证得到,特征筛选后的 SVR 模型表现最佳,其平均绝对误差约为 0.18 m³/min,平均相对误差 3.26%,表明采取降维处理在一定程度上简化了工作量,同时也保证了模型预测效果。

参考文献(References):

- [1] 周世宁,林柏泉.煤矿瓦斯动力灾害防治理论及控制技术[M].北京:科学出版社:2007:1-14.
- [2] 秦冰,郝建峰,梁冰,等.煤与瓦斯共采非线性约束多变量时空协同优化模型[J].煤炭学报,2019,44(S2): 593-600.
QIN Bing,HAO Jianfeng,LIANG Bing. et al. Influence of mining activities on mine rockmass and control engineering[J]. Journal of China Coal Society, 2019, 44 (S2): 593-600.
- [3] 王艳晖,李国勇,王炳莹.MFOA-SVM 在采煤工作面瓦斯涌出量预测中的应用[J].矿业安全与环保,2016, 43(2): 54-58.
WANG Yanhui, LI Guoyong, WANG Bingxuan. Application of MFOA-SVM in coalface gas emission predic-

- tion[J]. Mining Safety & Environmental Protection, 2016, 43(2): 54-58.
- [4] 董晓雷,贾进章,白洋,等.基于 SVM 耦合遗传算法的回采工作面瓦斯涌出量预测[J].安全与环境学报, 2016,16(2):114-118.
DONG Xiaolei, JIA Jinzhang, BAI Yang, et al. Prediction for gas-gushing amount from the working face of stope based on the SVM coupling genetic algorithm [J]. Journal of Safety and Environment. 2016, 16(2): 114-118.
- [5] 王生全,刘柏根,井津,等.矿井瓦斯涌出量建模预测[J].西安科技大学学报,2010,30(3):271-274.
WANG Shengquan, LIU Baigen, JING Jin, et al. Prediction of mine gas emission quantity[J]. Journal of Xi'an University of Science and Technology, 2010, 30 (3): 271-274.
- [6] 崔鸿雁,徐帅,张利锋,等.机器学习中的特征选择方法研究及展望[J].北京邮电大学学报,2018,41(1): 1-12.
CUI Hongyan, XU Shuai, ZHANG Lifeng, et al. The key techniques and future vision of feature selection in machine learning[J]. Journal of Beijing University of Posts and Telecommunications, 2018, 41(1): 1-12.
- [7] 李树刚,马彦阳,林海飞,等.基于因子分析法的瓦斯涌出量预测指标选取[J].西安科技大学学报,2017, 37(4):461-466.
LI Shugang, MA Yanyang, LIN Haifei, et al. Selection of gas emission prediction index based on factor analysis[J]. Journal of Xi'an University of Science and Technology, 2017, 37(4): 461-466.
- [8] 卢国斌,康晋恺,白刚,等.PCA-BP 在回采工作面瓦斯涌出量预测中的应用[J].辽宁工程技术大学学报(自然科学版),2015,34(12):1329-1334.
LU Guobin, KANG Jinkai, BAI Gang, et al. Application of PCA and BP to gas emission prediction of mining working face[J]. Journal of Liaoning Technical University(Natural Science), 2015, 34(12): 1329-1334.
- [9] 付华,赵俊程,付昱,等.基于量子粒子群与深度学习的煤矿瓦斯涌出量软测量[J].仪器仪表学报,2021, 42(4):160-168.
FU Hua, ZHAO Juncheng, FU Yu, et al. Soft measurement of coal mine gas emission based on quantum-behaved particle swarm optimization and deep learning [J]. Chinese Journal of Scientific Instrument, 2021, 42 (4): 160-168.
- [10] 吴奉亮,霍源,高佳南.基于随机森林回归的煤矿瓦斯涌出量预测方法[J].工矿自动化,2021,47(8): 102-107.

- WU Fengliang, HUO Yuan, GAO Jianan. Coal mine gas emission prediction method based on random forest regression[J]. Industry and Mine Automation, 2021, 47(8): 102–107.
- [11] 汪明, 王建军. 基于随机森林的回采工作面瓦斯涌出量预测模型[J]. 煤矿安全, 2012, 43(8): 182–185.
- WANG Ming, WANG Jianjun. Gas emission prediction model of stope based on random forests[J]. Safety in Coal Mines, 2012, 43(8): 182–185.
- [12] 王鹏新, 齐璇, 李俐, 等. 基于随机森林回归的玉米单产估测[J]. 农业机械学报, 2019, 50(7): 237–245.
- WANG Pengxin, QI Xuan, LI Li, et al. Estimation of maize yield based on random forest regression[J]. Transactions of the Chinese Society for Agricultural Machinery, 2019, 50(7): 237–245.
- [13] 李欣海. 随机森林模型在分类与回归分析中的应用[J]. 应用昆虫学报, 2013, 50(4): 1190–1197.
- LI Xinhai. Using “random forest” for classification and regression[J]. Chinese Journal of Applied Entomology, 2013, 50(4): 1190–1197.
- [14] 邢晓语, 杨秀春, 徐斌, 等. 基于随机森林算法的草原地上生物量遥感估算方法研究[J]. 地球信息科学学报, 2021, 23(7): 1312–1324.
- XING Xiaoyu, YANG Xiuchun, XU Bin, et al. Remote sensing estimation of grassland above ground biomass based on random forest[J]. Journal of Geoinformation Science, 2021, 23(7): 1312–1324.
- [15] 宋建国, 高强山, 李哲. 随机森林回归在地震储层预测中的应用[J]. 石油地球物理勘探, 2016, 51(6): 1202–1211.
- SONG Jianguo, GAO Qiangshan, LI Zhe. Application of random forests for regression to seismic reservoir prediction[J]. Oil Geophysical Prospecting, 2016, 51(6): 1202–1211.
- [16] 杨威, 李维刚, 赵云涛, 等. 基于随机森林的钢材性能预报与影响因素筛选[J]. 钢铁, 2018, 53(3): 44–49.
- YANG Wei, LI Weigang, ZHAO Yuntao, et al. Mechanical property prediction of steel and influence factors selection based on random forests[J]. Iron and Steel, 2018, 53(3): 44–49.
- [17] 霍娟, 孙晓伟, 张明杰. 电力负荷预测算法比较—随机森林与支持向量机[J]. 电力系统及其自动化学报, 2019, 31(7): 129–134.
- HUO Juan, SUN Xiaowei, ZHANG Mingjie. Comparison between power load forecasting algorithms based on random forest and support vector machine[J]. Proceedings of the CSU-EPSA, 2019, 31(7): 129–134.
- [18] Breiman L. Random forests[J]. Machine Learning, 2001, 45(1): 5–32.
- [19] 朱红青, 常文杰, 张彬. 回采工作面瓦斯涌出 BP 神经网络分源预测模型及应用[J]. 煤炭学报, 2007(5): 504–508.
- ZHU Hongqing, CHANG Wenjie, ZHANG Bin. Different-source gas emission prediction model of working face based on BP artificial neural network and its application[J]. Journal of China Coal Society, 2007(5): 504–508.
- [20] 付华, 谢森, 徐耀松, 等. 基于 ACC-ENN 算法的煤矿瓦斯涌出量动态预测模型研究[J]. 煤炭学报, 2014, 39(7): 1296–1301.
- FU Hua, XIE Sen, XU Yaosong, et al. Gas emission dynamic prediction model of coal mine based on ACC-ENN algorithm[J]. Journal of China Coal Society, 2014, 39(7): 1296–1301.
- [21] 张新生, 蔡宝泉. 基于改进随机森林模型的海底管道腐蚀预测[J]. 中国安全科学学报, 2021, 31(8): 69.
- ZHANG Xinsheng, CAI Baoquan. Corrosion prediction of submarine pipelines based on improved random forest model [J]. China Safety Science Journal, 2021, 31(8): 69.
-
- 作者简介: 成小雨(1989—), 陕西渭南人, 高级工程师, 博士, 主要从事矿井瓦斯防治方面的研究。
-
- (收稿日期: 2022-06-10; 责任编辑: 谭成威)

